



5



14



1680 sp

نظري

كلية الهندسة المعلوماتية

السنة الرابعة

Uncertainty & Bayesian Theory

د. عمر حمدون
غير مخصص للبيع التجاري



RB Informatix; 28/05/2025

نظم قواعد المعرفة

لقد تعودنا في النماذج التقليدية على فرضية أن القواعد والحقائق والمعرفة بشكل عام هي صحيحة 100% (*perfect knowledge*) أي بالنتيجة فإن القاعدتين التاليتين محقتين دائماً:

IF A is TRUE **then** A is NOT FALSE **and IF** A is FALSE **then** A is NOT TRUE

ولكن كما نعلم أنه في الواقع هذا الشيء لا يمكن ضمانه فليست كل الحقائق أو القواعد بالضرورة صحيحة مطلقاً، ومن هنا جاء ما يسمى بالشك *uncertainty*.

مبدأ الـ Uncertainty


- من الخصائص الشائعة للمعلومات المتوفرة لدى خبراء البشريين عدم كمالها.
- قد تكون المعلومات ناقصة incomplete، أو غير متسقة inconsistent، أو غير مؤكدة uncertain، أو حتى تشمل كل هذه العيوب معاً
- ومع ذلك، يستطيع الخبير التعامل مع هذه العيوب، وعادةً ما يتخذ قرارات صحيحة.
- لذلك، يجب على أنظمة الخبراء أيضاً أن تكون قادرة على معالجة عدم اليقين والوصول إلى استنتاجات صحيحة.
- هو مبدأ لمعالجة مشكلة الوثوقية في نظم قواعد المعرفة ويوجد ثلاثة حلول لهذه المشكلة، درسنا الحل الأول باستخدام certainty factor وهو أن نعطي نسبة شك لكل fact و rule موجودة في النظام وتكون بين 0 و 1.

عدم اليقين في أنظمة الخبراء:

- المنطق الكلاسيكي لا يسمح إلا بالاستدلال الدقيق "exact reasoning".
- ويفترض دائماً أن المعرفة المتوفرة صحيحة وكاملة، أي
- IF A is true THEN A is not false
- IF B is false THEN B is not true

لكن في الحياة الواقعية:

- معظم المشاكل الواقعية التي يمكن استخدام أنظمة الخبراء فيها لا توفر مثل هذه المعرفة الواضحة.
- غالباً ما تحتوي المعلومات المتاحة على بيانات غير دقيقة أو ناقصة أو غير قابلة للقياس.



أنواع عدم اليقين

1. معرفة غير مثالية Imperfect domain knowledge :


هي المعلومات المأخوذة من الخير، قد تكون مبهمّة أو ناقصة
مثال: خبراء يستخدمون "قواعد عامة"

2. بيانات غير مثالية Imperfect case data :

امثلة :

أجهزة استشعار غير موثوقة
اختبارات مكلفة أو مدمرة

غالبًا ما يكون من الأفضل استخدام بيانات تقريبية بدلاً من انتظار بيانات دقيقة وكاملة.



1. الغموض Ambiguity :

يمكن تفسير شيء ما بأكثر من طريقة
مثال: "أغلق الصنبور" ← أي صنبور؟

2. عدم الاكتمال Incompleteness :

المعلومات ناقصة
مثال: "أغلق الصنبور 1" ← أي اتجاه؟

3. عدم الصحة Incorrectness :

- أخطاء بشرية
مثل :قراءة خاطئة غير مقصودة لمؤشر أو بيانات.
مثال: يتم إطفاء الضوء بينما كان من المفترض أن يكون مشغلاً.
- عطل في الأجهزة
مثل: خلل أو قصور في المعدات المستخدمة قد يؤدي إلى معلومات غير صحيحة.

4. خطأ القياس Measurement Error :

- يتعلق بالدقة precision.
- يخبرنا مدى دقة القياس.
- يتعلق "بالضوضاء" في القياس.
- غالبًا ما يتم التعبير عنه كمجال (نطاق).
- مثال : مجال $\pm 0.1 - 2m$.



5. خطأ منهجي : Systematic Error

- ناتج عن بعض التحيز bias
- مثال: miscalibration of a ruler خطأ في معايرة مسطرة.

مصادر المعرفة غير المؤكدة في أنظمة الخبراء

- تداعيات / ضعيفة Weak implications
- لغة غير دقيقة Imprecise language
- بيانات غير معروفة Unknown data
- صعوبة الجمع بين آراء خبراء مختلفين

1. Weak Implications :

- غالباً ما تعاني أنظمة الخبراء المعتمدة على القواعد من روابط ضعيفة وعلاقات غامضة بين المعلومات.
- لذلك، يجب أن تكون أنظمة الخبراء قادرة على معالجة هذه العلاقات الغامضة.
- على سبيل المثال: يمكن التعامل مع هذه الغموضات من خلال قبول درجة الترابط بين الحقائق على شكل عوامل يقين رقمية (Certainty Factors).

2. لغة غير دقيقة Imprecise Language :

- اللغات الطبيعية Natural language غامضة وغير دقيقة بطبيعتها.
- نصف الحقائق بمصطلحات مثل:
- غالباً، أحياناً، بشكل متكرر، نادراً.
- ولكن إذا كانت هذه المصطلحات مقياسة (quantified) فيمكن استخدامها في أنظمة الخبراء.

تحديد المصطلحات غير الدقيقة (Quantifying the Meaning of Terms) :

في عام 1944، طلب راي سيمبسون من 355 طالباً في المدارس الثانوية والجامعات أن يضعوا 20 مصطلحاً شائع الاستخدام مثل "غالباً often" على مقياس من 1 إلى 100 لتحديد مدى تكرار كل مصطلح من وجهة نظرهم. وفي عام 1968، قام ميلتون هاكل (Milton Hakel) بتكرار نفس التجربة للتحقق من النتائج.

Ray Simpson (1944)		Milton Hakel (1968)	
Term	Mean value	Term	Mean value
Always	99	Always	100
Very often	88	Very often	87
Usually	85	Usually	79
Often	78	Often	74
Generally	78	Rather often	74
Frequently	73	Frequently	72
Rather often	65	Generally	72
About as often as not	50	About as often as not	50
Now and then	20	Now and then	34
Sometimes	20	Sometimes	29
Occasionally	20	Occasionally	28
Once in a while	15	Once in a while	22
Not often	13	Not often	16
Usually not	10	Usually not	16
Seldom	10	Seldom	9
Hardly ever	7	Hardly ever	8
Very seldom	6	Very seldom	7
Rarely	5	Rarely	5
Almost never	3	Almost never	2
Never	0	Never	0



Quantification of ambiguous and imprecise terms on a time-frequency scale

3. بيانات غير معروفة unknown data:

عندما تكون البيانات **ناقصة** أو **مفقودة**، فإن الحل الوحيد هو قبول القيمة على أنها "**غير معروفة unknown**" ثم نتابع باستخدام استدلال **تقريبي** يعتمد على هذه القيمة.

4. دمج آراء خبراء مختلفين:

في الأنظمة الخبيرة الكبيرة، يتم عادةً دمج معرفة وخبرة عدة خبراء. لكن للأسف، نادراً ما يتفق الخبراء على نفس الاستنتاج تماماً.

وغالباً ما تكون لديهم آراء متضاربة، وينتج عن ذلك **قواعد متناقضة**.

ولحل هذا التضارب، يحتاج مهندس المعرفة إلى تحديد **وزن** معين لكل خبير، ومن ثم حساب استنتاج مركّب بناءً على هذه الأوزان. **ومع ذلك، لا توجد طريقة منهجية واضحة لتحديد هذه الأوزان بدقة.**

إذن :

يجب أن تكون الأنظمة الخبيرة قادرة على التعامل مع حالات عدم اليقين، لأن أي مجال في العالم الحقيقي يحتوي على معرفة غير دقيقة. كما يجب أن تكون قادرة على التعامل مع البيانات غير الكاملة أو غير المتناسقة، أو حتى المفقودة.

تقنيات معالجة عدم اليقين

تم تطوير عدد من الطرائق العددية وغير العددية للتعامل مع عدم اليقين في أنظمة الخبراء المعتمدة على القواعد. ومن أشهر نماذج إدارة عدم اليقين:



- نظرية الاحتمالات (Bayesian Probability Theory)
- (Certainty Factor)
- (Fuzzy Set Theory)

لنتعرف بداية على الفرق بين المفهوم الرياضي لكل من نظرية الاحتمال والاحصاء الرياضي.

3. مثال: ما احتمال هطول الأمطار في شهر حزيران؟

- بديهياً نجد أنه احتمال قليل جداً (شبه مستحيل) أن تهطل الأمطار في فصل الصيف نظراً لخبرتنا السابقة، وهذا ما يدعى بالاحصاء الرياضي أي بناءً على إحصاءات ومعلومات سابقة نستنتج احتمال حدث معين.
- بحسب نظرية الاحتمال فإن احتمال هطول الأمطار هو 50٪.
- وفي النظم الخبيرة نستخدم الاحتمالات الناتجة عن الإحصاء سواء كانت إحصاء من بيانات قديمة ويتم عن طريقها استنتاج هذا الاحتمال، أو عن طريق خبرة خبير ضمن المجال الذي تتم معالجته.

- ❖ **احتمال وقوع حدث:** يعرف بأنه نسبة الحالات التي يحدث فيها هذا الحدث، ويمكن التعبير عنه رياضياً أنه مؤشر رقمي تتراوح قيمته بين الصفر (حالة مستحيلة بشكل مطلق) والواحد (حالة وقوع الحدث بتأكد مطلق)، وهو عدد مرات وقوعه على عدد مرات عدم وقوعه.
- ❖ **الاحتمال:** هو قيمة بين الصفر والواحد.
- ❖ **احتمال نجاح التجربة:** هو عدد مرات نجاح التجربة على عدد مرات تكرار التجربة.
- ❖ **الاحتمال الرياضي الحقيقي:** لا يهتمنا في نظام المعرفة (نحن لا نريد الاحتمال الرياضي).



القانون الأساسي بالإحصاء Basic Statistical Theory

- لنفرض أن s هو عدد مرات وقوع الحدث X_i و f هو عدد مرات عدم وقوعه فيكون عدد مرات التجريب الكلي هو $s + f$ ولحساب احتمال وقوع الحدث X_i نكتب:

$$P(\text{success}_{X_i}) = \frac{s}{s + f} = p$$

- ولحساب احتمال فشل الحدث X_i نكتب:

$$P(\text{failure}_{X_i}) = \frac{f}{s + f} = q$$

- مثال في امتحان ما نجح 75 طالب ورسب 25 طالب عندها يكون احتمال النجاح إحصائياً 75% واحتمال الرسوب 25% تبعاً.



- **اجتماع عدة أحداث:** هو احتمال وقوع حدثين مختلفين معا او وقوع أي منهما.
- $P(A \text{ or } B) = P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
- **تقاطع عدة أحداث:** هو احتمال وقوع كلا الحدثين ويساوي عدد عناصر فضاء التقاطع على عدد عناصر فضاء العينة، أما احتمال تقاطع عدة أحداث **مستقلة** فيساوي جداءها.

$$P(A \cap B) = \frac{n(A \cap B)}{n(s)} = P(A) \times P(B)$$

الاحتمالات المركبة باستخدام التقاطع والاجتماع

مثال عند رمي نرد، ما احتمال الحصول على عدد فردي ويقبل القسمة على 3؟

- لنرمز لوقوع حدث الحصول على رقم فردي ب A ولنرمز لوقوع حدث الحصول على رقم يقبل القسمة على 3 ب B .
- عند رمي نرد واحد (أحداث مترابطة):



■ يكون عناصر فضاء العينة: $S = \{1,2,3,4,5,6\}$

ويكون عدد عناصر فضاء العينة هو $n(S) = 6$

$n(A) = 3$ ويكون $A = \{1,3,5\}$

$n(B) = 2$ ويكون $B = \{3,6\}$

■ وبالتالي يكون فضاء التقاطع هو: $n(A \cap B) = 1$ ويكون $A \cap B = \{3\}$

ومنه يكون احتمال وقوع التقاطع هو:

$$P(A \cap B) = \frac{n(A \cap B)}{n(S)} = \frac{1}{6}$$

■ حالة رمي قطعتين (أحداث منفصلة):

$$n(A) = 3$$

$$n(B) = 2$$

$$P(A) = \frac{n(A)}{n(S)} = \frac{3}{6} = \frac{1}{2}$$

$$P(B) = \frac{n(B)}{n(S)} = \frac{2}{6} = \frac{1}{3}$$

$$P(A \cap B) = P(A) \times P(B) = \frac{1}{2} \times \frac{1}{3} = \frac{1}{6}$$

حيث وقوع الحدث A منفصل عن وقوع الحدث B

احتمال الاجتماع: هو احتمال وقوع عدة أحداث ويمكن الاستعانة بالعلاقة:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

فمثلاً بمثال رمي النرد السابق:

$$P(A \cup B) = \frac{1}{2} + \frac{1}{3} - \frac{1}{6} = \frac{2}{3}$$

نظرية الاحتمالات الشرطية:

الاحتمال الشرطي: بفرض لدينا حدثين A, B غير متنافيين فإن احتمال وقوع الحدث A علماً أن B قد وقع

يسمى بالاحتمال الشرطي. يمكن حسابه بالعلاقة:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

والعكس أيضاً (احتمال وقوع الحدث B علماً أن A قد وقع):

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$



■ في مثال رمي النرد السابق يكون:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{1}{2}$$

الأحداث المتنافية (Mutually Exclusive Events)

- ❖ نقول عن حدثين أو أكثر إنهم متنافيين إذا كان من المستحيل أن يحدثوا في نفس الوقت.
- ❖ إذا كان الحدثان A و B متنافيين، فإن احتمال حدوث A أو B يساوي مجموع احتمالات كل واحد منهما.

مثال على الأحداث المتنافية :

تم رمي حجر نرد (مكعب) مرة واحدة.

الحدث A: الحصول على عدد فردي (1، 3، 5)

الحدث B: الحصول على عدد زوجي (2، 4، 6)

النتيجة:

الحدثان A و B متنافيان لأن من المستحيل أن نحصل على عدد فردي وزوجي في نفس الرمية.

كما يمكن كتابة قانون الاحتمال الشرطي الذي يدعى **بقانون بايز**، كالتالي:

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

حيث:

- $P(A|B)$ هو احتمال وقوع A علماً أن B قد وقع.
- $P(B|A)$ هو احتمال وقوع B علماً أن A قد وقع.
- $P(A)$ احتمال وقوع الحدث A.
- $P(B)$ احتمال وقوع الحدث B.
- يفترض أن A و B ليسا متنافيين.

■ مثال

- ليكن لدينا احتمال وقوع الحدث A (نجاح في مادة KBS) هو $P(A) = 0.7$
- واحتمال وقوع الحدث B (التقديم بشكل جيد في الامتحان) هو $P(B) = 0.8$
- ولدينا $P(B|A) = 0.9$ احتمال تقديم امتحان المادة بشكل جيد علماً أنك نجحت في المادة، نستطيع بناء على ما سبق حساب $P(A|B)$ احتمال أن ينجح الطالب في المادة علماً أنه قدم جيداً في الامتحان.

الحل:

بالتعويض في قانون بايز نجد:

$$P(A|B) = \frac{0.7 \times 0.9}{0.8} = 0.7875$$


مثال توضيحي:

ليكن الحدث الأول تعطل السيارة، والحدث الثاني تعطل البطارية. ما احتمال تعطل البطارية علماً أن السيارة معطلة؟

إحصائياً وبناءً على البيانات السابقة لدى الميكانيكي نستطيع الإجابة على هذا السؤال. لكنه لا يستطيع الإجابة على الاحتمال المعاكس (احتمال تعطل السيارة علماً أن البطارية معطلة) ولهذا نحتاج لقانون بايز فيساعدنا على الانتقال بين الاحتمالات الشرطية.

■ إذاً في قانون بايز:

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$



■ نجد من السهل حساب الاحتمال الشرطي $P(B|A)$ ونعلم مسبقاً احتمال $P(A)$

■ لكن من الصعب حساب $P(B)$ لذلك لنجد طريقة أخرى لحسابه إحصائياً

■ الحدث B يعتمد حدوثه على الحدثين A و not A فقط، ومنه نجد:

$$P(B) = P(B|A) \times P(A) + P(B|\neg A) \times P(\neg A)$$

هذا الجزء لدينا مسبقاً من البسط

نحسب هذا الجزء بنفس طريقة حسابه
بالبسط إحصائياً

بالعودة لمثال عطل السيارة يمثل $P(A|B)$ احتمال تعطل السيارة علماً أن البطارية معطلة.

مثال:

لتكن لدينا الأحداث التالية:

❖ $P(B) = 0.3$ احتمال الإصابة بانفلونزا

❖ $P(A|B) = 0.8$ احتمال ارتفاع حرارة الجسم علماً أنه مصاب بانفلونزا

❖ $P(A|\neg B) = 0.4$ احتمال ارتفاع حرارة الجسم علماً أنه غير مصاب بالانفلونزا

والمطلوب حساب احتمال ارتفاع الحرارة $P(A)$

لاحظ أن كل من الاحتمالات محسوبة إحصائياً. بحسب القانون السابق نجد:

$$P(A) = P(A|B) \times P(B) + P(A|\neg B) \times P(\neg B)$$

نعوض

$$P(A) = 0.8 \times 0.3 + 0.4 \times 0.7 = 0.52$$

النجاح ليس دليلاً، ولكن النجاح هو الأفعال والنهائية.

Prior & Posterior Probability

احتمال كل من A و B تدعى بالاحتمالات المسبقة Prior Probabilities:


Prior Probabilities

وهي الاحتمالات غير المشروطة (لا تتعلق بأي أحداث أخرى) تُسند لحدث ما في غياب المعرفة التي تدعم حدوثه أو غيابه، أي احتمال وقوع حدث قبل أي دليل $p(event)$ كاحتمال تعطل السيارة بشكل عام، أو احتمال النجاح بامتحان KBS.

نعرف أيضا الاحتمال Posterior Probability:

Posterior Probabilities

Posterior Probability أو الاحتمال الشرطي أي احتمال حدث ما بوجود دليل evidence على حدوثه $p(event|evidence)$ مثال: احتمال نجاح الطالب علما أنه قد حضر جميع الجلسات العملية.



- تمثل ال H_i الفرضيات التي لدينا والمتعلقة بالأدلة $E_1, E_j, \dots, E_m$ عن طريق الاحتمال الشرطي $P(E_j|H_i)$
- والهدف هو حساب الاحتمال $P(H_i|E_j)$ عن طريق قانون بايز.

- بداية سنعتبر أن لدينا دليل وحيد هو E ثم نعمم من أجل أكثر من دليل (Evidence)، بتطبيق قانون بايز نجد:

$$P(H|E) = \frac{P(E|H) \times P(H)}{P(E)}$$

$$P(H|E) = \frac{P(E|H) \times P(H)}{P(E|H) \times P(H) + P(E|\neg H) \times P(\neg H)}$$

- الآن وباعتبار لدينا أكثر من دليل (Evidence) فيكون القانون مبدئياً:

$$P(H_i|E_1, \dots, E_n) = P(E_1, \dots, E_n|H_i) \times \frac{P(H_i)}{P(E_1, \dots, E_n)}$$



نلاحظ أن حساب الاحتمال $P(E_1, \dots, E_n | H_i)$ مكلف جداً لذلك نفترض أن جميع ال Evidences مستقلة عن بعضها حيث نحاول أثناء بناء النظام أن تكون جميع ال Evidences التي نستخدمها مستقلة فيما بينها بحيث تحقق القيدين:

ME (mutually exclusive): $E_i \wedge E_j = \emptyset$, $(P(E_i \wedge E_j) = 0), i, j = 1, \dots, n, i \neq j$

EX (exhaustive): $E_1 \vee \dots \vee E_n = S$, $(P(E_1 \vee \dots \vee E_n) = 1)$

حيث S فضاء العينة.

- بالعودة للقانون:

$$P(H_i | E_1, \dots, E_n) = P(E_1, \dots, E_n | H_i) \times \frac{P(H_i)}{P(E_1, \dots, E_n)} \quad \dots (*)$$

وبتحقيق أنهم مستقلين نستطيع الانتقال للعلاقة:

$$P(H_i | E_1, \dots, E_n) = \frac{P(E_1 | H_i) \times P(E_2 | H_i) \times \dots \times P(E_n | H_i) \times P(H_i)}{\sum_k P(E_1 | H_k) \times P(E_2 | H_k) \times \dots \times P(E_n | H_k) \times P(H_k)}$$

حيث أصبحت ال Evidence مرتبطة بال H_i بشكل مباشر لذلك استطعنا الانتقال من الشكل:

$$P(E_1, \dots, E_n | H_i) \times P(H_i)$$

إلى الشكل:

$$P(E_1 | H_i) \times P(E_2 | H_i) \times \dots \times P(E_n | H_i) \times P(H_i)$$

وذلك في البسط، أما بالنسبة للمقام فبالعودة للعلاقة * حيث كنا نتعامل مع فرضية واحدة (تحققها أو عدمه)

أما هنا فتعامل مع أكثر من فرضية فعدم تحقق إحداها يعني تحقق أخرى وبالتالي ينتقل المقام من الشكل:

$$P(E_1, \dots, E_n)$$

إلى الشكل:

$$\sum_k (P(E_1 | H_k) \times P(E_2 | H_k) \times \dots \times P(E_n | H_k) \times P(H_k))$$

أي بكلام آخر احتمال وقوع الحدث $P(E_1, \dots, E_n)$ وذلك من أجل جميع الفرضيات الموجودة (والتي عددها k).

مثال بفرض هناك طالب يريد معرفة احتمالية نجاحه بمادة معينة وذلك بوجود الفرضيات Hypothesis (H).

Hypothesis 1:

pass the assignment and the subject

نجاحه بالمقرر (عملي ونظري).

Hypothesis 2:

pass the assignment but fail the subject

نجاحه بالعملي ورسوبه بالنظري.

Hypothesis 3:

fail the subject

الرسوب في المادة

علماً أن النجاح برأيه يعتمد على عوامل مختلفة (Evidence (E) هي:

❖ Evidence 1: attend all the practical sessions

حضور كل جلسات العملي.

❖ Evidence 2: spend at least 3 hours in the cafeteria at lunchtime every week day

قضاء ثلاث ساعات في المقهى وقت الغداء كل يوم.

❖ Evidence 3: study the text book

الدراسة من الكتاب المقرر

بعد زهاب الطالب لخبير في استراتيجيات النجاح في المادة يصبح لديه الجدول التالي (يمكن حسابه إحصائياً):

Hypothesis			
$i = 3$	$i = 2$	$i = 1$	
0.2	0.1	0.7	$Pr(H_i)$
0.1	0.5	0.8	$Pr(E_1 H_i)$
0.7	0.5	0.3	$Pr(E_2 H_i)$
0.05	0.3	0.7	$Pr(E_3 H_i)$

الحل:

1. احسب احتمال $Pr(H1 | E1)$ ، وهو احتمال النجاح في المقرر (عملي ونظري) إذا تم حضور كافة جلسات العملي:

يمكن حسابه من العلاقة:

$$Pr(H1 | E1) = \frac{Pr(E1|H1) \times Pr(H1)}{Pr(E1|H1) \times Pr(H1) + Pr(E1|H2) \times Pr(H2) + Pr(E1|H3) \times Pr(H3)}$$

$$= \frac{0.7 \times 0.8}{0.7 \times 0.8 + 0.10 \times 0.5 + 0.2 \times 0.1} = \frac{0.56}{0.63} = 0.889$$

2. احسب احتمال $Pr(H3|E2)$ وهو احتمال الرسوب بالمقرر (عملي ونظري) إذا كان يقضي على الأقل ثلاث ساعات في المقهى وقت الغداء:

يمكن حسابه من العلاقة:

$$P(H3 | E2) = \frac{Pr(E2|H3) \times Pr(H3)}{Pr(E2|H1) \times Pr(H1) + Pr(E2|H2) \times Pr(H2) + Pr(E2|H3) \times Pr(H3)}$$

$$= \frac{0.2 \times 0.7}{0.3 \times 0.7 + 0.5 \times 0.10 + 0.7 \times 0.2} = \frac{0.14}{0.40} = 0.35$$

3. احسب احتمال $Pr(H1|E1, E3)$ وهو احتمال النجاح في المقرر (عملي ونظري) إذا تم حضور كافة جلسات العملي إضافة للدراسة من الكتاب:

يمكن حسابه من العلاقة:

$$\begin{aligned}
 & P(H1|E1, E3) \\
 &= \frac{\Pr(E_1|H_1) \times \Pr(H_1) \times \Pr(E_3|H_1)}{\Pr(E_1|H_1) \times \Pr(H_1) \times \Pr(E_3|H_1) + \Pr(E_1|H_2) \times \Pr(H_2) \times \Pr(E_3|H_2) + \Pr(E_1|H_3) \times \Pr(H_3) \times \Pr(E_3|H_3)} \\
 &= \frac{0.8 \times 0.7 \times 0.7}{0.8 \times 0.7 \times 0.7 + 0.5 \times 0.10 \times 0.3 + 0.1 \times 0.2 \times 0.05} = \frac{0.392}{0.392 + 0.015 + 0.001} = 0.961
 \end{aligned}$$

4. احسب احتمال النجاح في المقرر (عملي ونظري) إذا كان يقضي ثلاث ساعات على الأقل في المقهى وقت الغداء $Pr(H1|E2)$

يمكن حسابه من العلاقة:

$$\begin{aligned}
 & \Pr(H1|E2) \\
 &= \frac{\Pr(E2|H1) \times \Pr(H1)}{\Pr(E2|H1) \times \Pr(H1) + \Pr(E2|H2) \times \Pr(H2) + \Pr(E2|H3) \times \Pr(H3)} \\
 &= \frac{0.3 \times 0.7}{0.3 \times 0.7 + 0.5 \times 0.1 + 0.7 \times 0.2} = \frac{0.21}{0.4} = 0.525
 \end{aligned}$$

5. احسب احتمال $p(H1|E1, E2, E3)$ وهو احتمال النجاح في المقرر (عملي ونظري) اذا تم حضور كافة جلسات العملي و الدراسة من الكتاب وتم قضاء على الاقل 3 ساعات في المقهى وقت الغداء:



$$p(H_1|E_1, E_2, E_3)$$

$$\begin{aligned}
 &= \frac{\Pr(E_1|H_1) * \Pr(E_2|H_1) * \Pr(E_3|H_1) * \Pr(H_1)}{\left[\begin{aligned} & \Pr(E_1|H_1) \times \Pr(E_2|H_1) \times \Pr(E_3|H_1) \times \Pr(H_1) \\ & + \Pr(E_1|H_2) \times \Pr(E_2|H_2) \times \Pr(E_3|H_2) \times \Pr(H_2) \\ & + \Pr(E_1|H_3) \times \Pr(E_2|H_3) \times \Pr(E_3|H_3) \times \Pr(H_3) \end{aligned} \right]} \\
 &= \frac{0.80 \times 0.30 \times 0.70 \times 0.70}{(0.80 \times 0.30 \times 0.70 \times 0.70 + 0.50 \times 0.50 \times 0.30 \times 0.10 + 0.10 \times 0.70 \times 0.05 \times 0.20)} \\
 &= \frac{0.1176}{0.1258} = 0.9348
 \end{aligned}$$

■ مثال 2: تُحاول طبيبة استخدام منطق بايز الاحتمالي لحساب احتمال إصابة مريضها بفيروس قاتل ويتطلب دخول المستشفى. تعتقد الطبيبة أن هناك عدة احتمالات تشخيصية. وقد أدرجت هذه الاحتمالات كفرضيات كما يلي:

Hypothesis 1:

patient has deadly virus and needs hospitalization
المريض مصاب بفيروس قاتل ويحتاج إلى دخول المستشفى.

Hypothesis 2:

patient is feeling ill, but it is not a serious infection
المريض يشعر بالتوعك، ولكن ليس بسبب عدوى خطيرة.

Hypothesis 3:

patient is well
المريض بصحة جيدة.

وهناك العديد من الأدلة أو السلوكيات التي بمجرد ملاحظتها، تُغير من احتمال إصابة المريض بالمرض بسبب الفيروس.

❖ Evidence 1: patient has a bad rash and blisters

ظهور طفح جلدي وحويصلات لدى المريض.

❖ Evidence 2: patient has a very high temperature.

ارتفاع درجة حرارة المريض بشكل كبير.

❖ Evidence 3: patient has a healthy appetite.

شهية المريض طيبة.

تستشير الطبيبة نصوصاً طبية. يُذكر فيها أن الاحتمالات التالية:

Hypothesis			
$i = 3$	$i = 2$	$i = 1$	
0.75	0.20	0.05	$\Pr(H_i)$
0.00	0.40	0.5	$\Pr(E_1 H_i)$
0.00	0.40	0.4	$\Pr(E_2 H_i)$
0.80	0.30	0.1	$\Pr(E_3 H_i)$



المطلوب حساب:

1. احسب $\Pr(H_1 | E_1)$ وهو احتمال إصابة المريض بفيروس واحتياجه إلى دخول المستشفى مع العلم بظهور طفح جلدي وحويصلات لديه.

$$\Pr(H_1|E_1) =$$

$$\begin{aligned}
 & \frac{Pr(E_1|H_1) * Pr(H_1)}{Pr(E_1|H_1) * Pr(H_1) + Pr(E_1|H_2) * Pr(H_2) + Pr(E_1|H_3) * Pr(H_3)} \\
 &= \frac{0.50 * 0.05}{0.50 * 0.05 + 0.40 * 0.20 + 0.00 * 0.75} \\
 &= \frac{0.025}{0.105} = 0.238
 \end{aligned}$$

2. احسب $Pr(H_3 | E_3)$ ، أي احتمال كون المريض بصحة جيدة، مع العلم أن لديه شهية صحية.

$$\begin{aligned}
 & Pr(H_3 | E_3) = \\
 & \frac{Pr(E_3 | H_3) \times Pr(H_3)}{Pr(E_3 | H_1) \times Pr(H_1) + Pr(E_3 | H_2) \times Pr(H_2) + Pr(E_3 | H_3) \times Pr(H_3)} \\
 &= \frac{0.80 \times 0.75}{0.10 \times 0.05 + 0.30 \times 0.20 + 0.80 \times 0.75} \\
 &= \frac{0.60}{0.005 + 0.06 + 0.60} = \frac{0.6}{0.665} = 0.902
 \end{aligned}$$

3. احسب $Pr(H_1 | E_1, E_2)$ ، أي احتمال إصابة المريض بفيروس قاتل واحتياجه إلى دخول المستشفى مع العلم بظهور طفح جلدي وحويصلات لديه وأيضاً ارتفاع شديد في درجة حرارته.

$$Pr(H_1 | E_1, E_2)$$



$$\begin{aligned}
 &= \frac{Pr(E_1|H_1) * Pr(E_2 | H_1) * Pr(H_1)}{\left[\begin{aligned} & Pr(E_1 | H_1) * Pr(E_2 | H_1) * Pr(H_1) \\ & + Pr(E_1 | H_2) * Pr(E_2 | H_2) * Pr(H_2) \\ & + Pr(E_1 | H_3) * Pr(E_2 | H_3) * Pr(H_3) \end{aligned} \right]}
 \end{aligned}$$

$$\begin{aligned}
 &= \frac{0.50 * 0.40 * 0.05}{0.50 * 0.40 * 0.05 + 0.40 * 0.40 * 0.20 + 0.00 * 0.30 * 0.75} \\
 &= 0.01 + 0.032 + 0.00 \\
 &= \frac{0.01}{0.042} = 0.238
 \end{aligned}$$



ملاحظة خارجية:

ينقسم ال machine Learning إلى *Generative ML* و *Discriminative ML*

ويعتمد ال-Generative ML على Bayesian Reasoning ولا يحتاج big data مثل ال-*Descrminitive ML*.